מעבדה בסטטיסטיקה – רשומות שיעור: פולינומים שבריים ובחירת מודל

Nov 8, 2026 · @adi ozana

רקע: למה מודל פשוט

המטרה היא לבנות עקומות גדילה חדשות לאוכלוסייה הישראלית, במודל שדומה במהותו למודל שמשתמשים בו היום. שתי מגבלות מעשיות דוחפות למודל פשוט:

- **יישום:** העקומות יוטמעו במערכת האולטרסאונד של כל בתי החולים והמרפאות. המערכת נבנתה על ידי חברה חיצונית והגמישות שלה מועטת. מודל מסובך פשוט לא ייכנס.
- **חשדנות רופאים:** רופאים שלא מבינים מודל לא ירצו להשתמש בו.

ולכן השיווק הקל ביותר הוא: "זה בדיוק המודל מהמאמר שאתם מכירים, רק התאמנו את המקדמים לאוכלוסייה הישראלית". כל פישוט נוסף הוא יתרון. למשל, אם אפשר להשתמש בסטיית תקן קבועה שלא משתנה עם השבוע.

פולינומים שבריים (Fractional Polynomials)

זו השיטה שבה פותחו העקומות הקיימות. הצעד הראשון המומלץ: להפעיל את אותה שיטה על הנתונים הישראליים.

כאן X הוא גיל ההריון. Y הוא המדד הביומטרי במודל התוחלת, ובמודל סטיית התקן הוא הערך המוחלט של השארית כפול $\sqrt{(\pi/2)}$.

```
Y = \beta_0 + \beta_1 X^{-2} + \beta_2 X^{-1} + \beta_3 X^{-1/2} + \beta_4
X^{1/2} + \beta_5 X + \beta_6 X^{2} + \beta_7 X^{3} + \beta_8 \log X +
\varepsilon
```

- קבוצת החזקות המקובלת: −2, −1, −0.5, 0, 0.5, 1, 2, 3. החזקה 0 מוגדרת כ-log X.
- בשיטה הכללית מותר גם להוסיף אינטראקציות, למשל X·log X.
- אותה צורה משמשת גם לתוחלת וגם לסטיית התקן.

למה דווקא המודל הזה:

1. **גמיש:** הוא מאפשר הרבה מאוד צורות של עקומה, לא רק קו ישר.
2. **עדיין רגרסיה לינארית:** הלינאריות היא במקדמים β, לא ב-X. הטרנספורמציות של X הן פשוט עמודות נוספות, ואפשר לאמוד בריבועים פחותים רגילים.

מולטיקולינאריות ומירכוז

בטווח של שבועות 14 עד 42, הפונקציה X^2 נראית כמעט לינארית, ולכן המתאם בין X ל-X^2 גבוה מאוד. זו מולטיקולינאריות: עמודות כמעט תלויות במטריצה, וקושי חישובי להפוך את (X^TX).

הפתרון הפשוט: מירכוז. מחליפים את X ב-$(X - c)$, למשל $c = 30$ או הממוצע. הערך המדויק של c לא חשוב. כשהערכים מפוזרים מסביב לאפס, המתאם יורד מאוד, ויכול להגיע אפילו לאפס.

שני המודלים שקולים. המקדמים שונים, אבל התחזית זהה:

```
Y = \beta_1 + \beta_2 X + \beta_3 X^2 + \varepsilon
\qquad\Longleftrightarrow\qquad Y = \gamma_1 + \gamma_2 (X-c) + \gamma_3 (X-
c)^2 + \varepsilon
```

פתיחת הסוגריים נותנת את המעבר בין המקדמים:

```
\beta_1 = \gamma_1 - \gamma_2 c + \gamma_3 c^2, \qquad \beta_2 = \gamma_2 -
2\gamma_3 c, \qquad \beta_3 = \gamma_3
```

- לא חייבים לחזור ל-β: המטרה היא לחשב תוחלת, והתוצאה זהה עם γ.
- ממרכזים רק את החזקות השלמות. **לא** את $\sqrt{X}$, $X^{-1/2}$ או $\log X$, שדורשים ארגומנט חיובי.
- רעיון כללי יותר הוא בסיס של פונקציות בלתי תלויות (אורתוגונליות). אז אפשר אפילו לאמוד כל מקדם בנפרד. כאן מספיק המירכוז הפשוט.

בחירת מודל: AIC ו-BIC

כל אחד מ-8 האיברים יכול להיות במודל או לא, כלומר יש $2^8 = 256$ מודלים אפשריים. צריך קריטריון לבחור ביניהם.

למה לא סתם נראות: תחת שגיאות נורמליות, רגרסיה נותנת את אומד הנראות המרבית. הוספת פרמטר לעולם לא מקטינה את הנראות, כי תמיד אפשר לשים לו מקדם 0. לכן מוסיפים קנס על מספר הפרמטרים ומחפשים מינימום. כאן k הוא מספר הפרמטרים, כולל σ^2, ו-n הוא מספר התצפיות.

```
\text{AIC}(M_k) = -2\log L(\hat\beta) + 2k \qquad\qquad \text{BIC}(M_k) =
-2\log L(\hat\beta) + k\log n
```

	AIC	BIC
מטרה	התחזית הטובה ביותר לתצפית חדשה	מציאת המודל הנכון

	AIC	BIC
מחיר לפרמטר נוסף	2, ללא תלות ב-n	n גדל עם log n,
הצדקה	אסימפטוטית, הקנס האופטימלי לתחזית; מגן מפני התאמה יתרה	אם המודל הנכון נמצא בין המודלים שנשקלים, כש-n → ∞ בוחרים אותו בהסתברות 1

- פירוש הקנס ב-AIC: מוסיפים פרמטר רק אם הוא מעלה את לוג הנראות בלפחות 1 (כלומר מוריד את −2logL בלפחות 2). המספר 2 לא שרירותי.
- ב-AIC התצפית החדשה היא בעלת X שנדגם מהתפלגות ה-X של המדגם.
- .פותח על ידי גדעון שוורץ מהמחלקה באוניברסיטה העברית, במסגרת בייזיאנית BIC
- לערך עצמו של AIC או BIC אין פירוש ואין לו יחידות. משווים רק בין מודלים על אותם נתונים, ולא משווים AIC ל-BIC.
- המרצה חושב שהמטרה של מציאת המודל הנכון מתאימה לנו יותר מתחזית של תצפית חדשה, אבל אפשר לחשוב על קריטריון מתאים עוד יותר (בסעיף הבא).

קריטריון מותאם לאחוזונים

מה שבאמת מעניין אותנו הוא שהאחוזונים 3, 5, 10, 95 ו-97.5 יהיו נכונים. לכן אפשר לבחור מודל לפי קריטריון שמודד את זה ישירות.

לכל מודל מועמד, אחרי אמידת $\hat{\mu}(x)$ ו-$\hat{\sigma}(x)$, מחשבים את האחוזון, בדיוק כמו שחושב עם המודל של Hadlock:

```
\hat Q_{p}(x) = \hat\mu(x) + z_{p}\,\hat\sigma(x)
```

אז בודקים את הפרופורציה האמפירית של תצפיות מתחת לקו, $\hat{\pi}_p(x)$, לכל שבוע. היינו רוצים שתהיה קרובה ל-p (למשל 0.03).

למה מרחק יחסי ולא מוחלט: טעות של חצי אחוז באחוזון 10 (0.095 במקום 0.10) קטנה. אותה טעות באחוזון 3 (0.025 במקום 0.03) חמורה הרבה יותר. לכן מנרמלים את המרחק, ועדיף במשהו בסגנון סטיית תקן, שגם סימטרי בין p ל-(1 − p). דוגמה לפונקציית קנס על כל השבועות:

```
C_p = \sum_{x} \frac{\left|\hat\pi_p(x) - p\right|}{\sqrt{p(1-p)}}
```

- לכמה אחוזונים ביחד ממצעים את הקנס על כל האחוזונים. בסוף יש מודל אחד לתוחלת ומודל אחד לסטיית התקן, לכל האחוזונים.
- זו דוגמה בלבד. המרצה מבקש להשקיע מחשבה בבחירת קריטריון שמתאים למה שרוצים לעשות.

אמידה משותפת מול דו-שלבית

המודל המלא מתאר ביחד את התוחלת ואת סטיית התקן, למשל:

```
Y_i \mid X_i \sim N\!\left(\mu(X_i),\, \sigma(X_i)^2\right), \qquad \mu(x) =
\beta_0 + \beta_1 x + \beta_2 \log x, \qquad \sigma(x) = \gamma_0 + \gamma_1
x
```

- **באופן פורמלי:** AIC ו-BIC דורשים לאמוד את β ו-γ יחד בנראות המשותפת. זה אפשרי אבל קשה.
- **בפועל (כמו במאמר):** אמידה בשני שלבים. קודם בוחרים מודל לתוחלת. ריבועים פחותים נותנים אומד טוב לתוחלת גם כשהשונות לא קבועה. אחר כך בוחרים מודל לסטיית התקן על השאריות, בהינתן התוחלת שנאמדה.
- זה קירוב שאולי לא יבחר את המודל הכי טוב במשפחה, אבל יבחר מודל טוב. התוצאות על AIC ו-BIC ממילא אסימפטוטיות ולא מדויקות במדגם סופי, ולכן הקירוב סביר.

הדגמה בסימולציה וחיפוש בין מודלים

המרצה דגם $n = 200$ תצפיות, עם x בין -5 ל-5, ממודל ש**אינו** במשפחת המודלים שנשקלים. המטרה: להמחיש שהמודל האמיתי לא בהכרח נמצא בין המודלים שמחפשים בהם.

```
E[Y\mid x] = \sin x + 0.5x + 0.03x^2, \qquad \operatorname{Var}
(\varepsilon\mid x) = 1 + 0.05x^2
```

(בתמלול נאמר "אחד ועוד חצי, $0.05x^2$". הנוסחה של השונות לא חד-משמעית, כדאי לבדוק בקוד שיישלח.)

התאמת פולינומים במעלות עולות: המודל הלינארי והריבועי חלשים. מעלה 3 נראית טוב בהרבה. מעלה 4 אולי אפילו פחות טובה. העלאת מעלה לא תמיד משפרת.

חישוב הקריטריונים: לוג הנראות מחושב עם logLik של הרגרסיה (בהנחת שגיאות נורמליות), והמרצה הראה שהחישוב הידני נותן את אותו ערך. ברגרסיה לינארית פשוטה יש 3 פרמטרים: β_0, β_1 ו-σ^2.

מעבר	AIC	BIC
לינארי ← מעלה 2	משתפר	מתקלקל
מעלה 2 ← מעלה 3	משתפר	מעלה 3 עדיפה על הלינארי
מעלה 3 ← מעלה 4	משתפר	מתקלקל
מעלה 4 ← מעלה 5	משתפר	משתפר

BIC	AIC	מעבר
—	מתקלקל	מעלה 5 ← מעלה 6
מעלה 5	**מעלה 5**	**נבחר**

איך מחפשים בין המודלים

- **כל התת-קבוצות (all subsets):** עם 8 משתנים יש 256 מודלים, וזה עדיין אפשרי חישובית. המרצה הראה ספרייה ל-stepwise שעם האפשרות "strategy = "subset עוברת על כל התת-קבוצות ומחזירה את הטובה ביותר. שם הספרייה לא נשמע בתמלול.
- **Stepwise (forward / backward):** הולך במסלול אחד בתוך מרחב המודלים. הוא מהיר יותר, אבל לא מובטח שימצא את הטוב ביותר.
- אפשר לכתוב פונקציה עצמאית שמריצה את החיפוש לפי קריטריון מותאם, למשל קריטריון האחוזונים.

מה צריך לעשות עכשיו

המטרה: מודל שדומה במהותו למודל הקיים, מותאם לנתונים הישראליים. בלי להוסיף משתנים או אינטראקציות חדשים.

שתי רמות שינוי לעומת המודל הקיים:

1. **אותה נוסחה, מקדמים חדשים.** קרוב ביותר למה שהרופאים מכירים.
2. **אותה שיטה, נוסחה שנבחרה מחדש.** מפעילים פולינומים שבריים עם אותן חזקות ובוחרים את המודל הטוב ביותר לישראל. דוגמה לאיך מציגים את זה: "הנוסחה שלהם הייתה עם x ו-x^3, ושלנו עם x^½ ו-log x". כדאי לעבור לזה רק אם השיפור ניכר.

- [ ] להתאים מודל פולינומים שבריים לתוחלת, ולמרכז את החזקות השלמות אם צריך
- [ ] להתאים מודל לסטיית התקן על $V(\pi/2)\cdot|\text{שארית}|$
- [ ] לבחור קריטריון לבחירת מודל (AIC, BIC או קריטריון אחוזונים משלכם) **ולנמק את הבחירה**
- [ ] לבדוק כמה המודל מצליח באחוזונים, **על קובץ האימון בלבד** (לא על קובץ הבדיקה), ולהשוות למודל המקורי

הערת המרצה לגבי התיק: בשנה ג' הקורס הזה יהיה פרויקט שתספרו עליו בראיונות עבודה. מבחינת הקורס, שיטה פשוטה בסדר כל עוד מנמקים אותה. מי שרוצה פרויקט משמעותי בתיק כדאי שינצל את ההזדמנות לשיטה שמתאימה יותר לבעיה, כמו קריטריון אחוזונים.