מעבדה בסטטיסטיקה – רשומות שיעור: תצפיות חריגות, סלקציה וחלוקה לאימון ובדיקה

Nov 8, 2026 · @adi ozana

רקע

השיעור עסק בהכנת נתוני האולטרסאונד לבניית מודל: ניקוי תצפיות חריגות, בדיקת סלקציה בהריונות עם הרבה בדיקות, וחלוקת הקובץ לקובץ אימון ולקובץ בדיקה.

- **הבעיה הכללית:** עקומות הגדילה המקובלות (Hadlock ו-Kurmanavicius) פותחו על אוכלוסיות ממדינות אחרות. בהצגות שבתחילת השיעור כל הקבוצות מצאו שהן לא מתאימות לנתונים מישראל, ולכן בהמשך הקורס נבנה עקומות חדשות.
- **המשתנה בהדגמה:** המרצה יצר משתנה של **משקל עובר משוער** (EFW), מחושב בנוסחה מכמה מדדים ביומטריים, כדי לא לעבוד על מדד של אחת הקבוצות.
- **למה משקל:** זה המדד שהרופאים עוקבים אחריו כמדד מסכם. הנוסחה נבנתה ממקרים שבהם הייתה מדידת אולטרסאונד ולידה סמוך אליה, כך שאפשר היה לשקול את העובר. המרצה ציין שאינו אוהב את המדד במיוחד, אבל זה המקובל בתחום.

זיהוי תצפיות חריגות ותקנון

השיטה: מתקננים כל מדידה לפי התוחלת וסטיית התקן של שבוע ההריון שלה, סופרים כמה תצפיות רחוקות יותר מ-k סטיות תקן, ומשווים למה שהתפלגות נורמלית הייתה נותנת.

שני סוגים של תצפיות חריגות

1. **טעויות** – טעות מדידה או הקלדה, במדד או בשבוע ההריון (למשל 35 במקום 25). אם הן קרו באופן מקרי ולא בגלל הערך עצמו, הסרתן מקטינה את המדגם אבל לא פוגעת בייצוגיות שלו.
2. **ערכים אמיתיים קיצוניים** – עובר שבאמת יש לו בעיית גדילה. את אלה לא רוצים להוריד, כי בדיוק הם קובעים את האחוזונים הקיצוניים.

אי אפשר להפריד בין הסוגים במוחלט, ולכן מורידים בזהירות. אם כל החריגות בצד אחד, הסרה בטעות מזיזה את האחוזונים. אם הן גם מעל וגם מתחת, הטעויות עשויות לקזז זו את זו.

שלב 1: הסרת ערכים בלתי אפשריים

בתרשים פיזור ראשוני של משקל מול שבוע היו 3 תצפיות מעל 10,000 גרם, מנותקות לגמרי מעננת הנתונים. הן הוסרו מיד, בלי קשר לתקנון.

שלב 2: מודל אד-הוק לתוחלת ("מודל אפס")

העקומות הקיימות לא מתאימות, ולכן מתאימים מודל פשוט שמטרתו רק לזהות חריגים, לא להיות מדויק. זו רגרסיה פולינומית ממעלה שלישית, כלומר רגרסיה ליניארית מרובת משתנים על week, week², week³:

```
W = \beta_0 + \beta_1\,\text{week} + \beta_2\,\text{week}^2 +
\beta_3\,\text{week}^3 + \varepsilon
```

- כל המקדמים יצאו מובהקים, גם המקדם של week³, בגלל גודל המדגם.
- הקו תופס את המגמה. בשבועות 14–15 הוא מעט גבוה מדי, כנראה כי מעלה 3 לא גמישה מספיק, אבל למטרה הזו זה מספיק.
- למה פולינום: כך בנויות גם עקומות הגדילה בספרות, וזו שיטה מהירה ופשוטה.

שלב 3: מודל לסטיית התקן כפונקציה של שבוע

מריצים רגרסיה של הערך המוחלט של השארית כפול 1.25 על week ו-week² (פונקציה ריבועית), כמו שעשו במאמרים של העקומות.

למה זה עובד: אם השארית נורמלית עם תוחלת 0, אז

```
E|\varepsilon| = \sigma\sqrt{\tfrac{2}{\pi}} \;\Rightarrow\;
E\!\left[\sqrt{\tfrac{\pi}{2}}\,|\varepsilon|\right] = \sigma, \qquad
\sqrt{\tfrac{\pi}{2}} \approx 1.25
```

רגרסיה אומדת את התוחלת המותנית של המשתנה התלוי. כאן התוחלת היא סטיית התקן, ולכן מקבלים אומדן לסטיית התקן בהינתן השבוע. סטיית התקן עולה עם השבוע (הטרוסקדסטיות).

שאלה מהכיתה: בסוף הטווח נראה שהקו לא תופס לגמרי את הפיזור. התשובה: ייתכן, קשה לראות כמה נקודות יש שם (נקודות קטנות יותר בגרף יעזרו), אבל מבחינת פונקציית המטרה של הרגרסיה זה הקו המייצג ביותר.

שלב 4: המשתנה המתוקנן

```
Z_i = \frac{W_i - \hat\mu(\text{week}_i)}{\hat\sigma(\text{week}_i)}
```

לא חייבים את השיטה הזו. אפשר גם לחשב ממוצע וסטיית תקן לכל שבוע, או לתקנן לפי העקומה (Hadlock או Kurmanavicius) שהתאימה לכם יותר טוב. העיקרון: משתנה מתוקנן באופן סביר לפי שבוע. זה שלב של "קצת אומנות", ואף אחד לא משלם על שיטה מדויקת יותר שמשנה עוד עשרה חריגים.

שלב 5: כמה חריגים יש, ואיפה

- מעל 3 סטיות תקן: 605 תצפיות. מעל 4: 162. מעל 5: 80. מעל 7: 21.
- חשוב לבדוק לא רק כמה יש, אלא גם איפה: מעל או מתחת לקו, ובאילו שבועות. כאן הן מפוזרות מעל ומתחת לאורך השבועות.
- בשבועות המוקדמים יש מעט חריגים למטה: המשקל קטן מאוד ולא יכול לרדת מתחת ל-0, ולכן כמה סטיות תקן מתחת לתוחלת כבר מגיעות לאפס.

שלב 6: בדיקת נורמליות של Z

- הממוצע של Z הוא 0.004 וסטיית התקן 1.075, לא בדיוק 0 ו-1. הסיבה: התקנון נעשה לכל שבוע בנפרד (לפי מודל), ואז איחדו את כל השבועות יחד.
- היסטוגרמה של Z עם צפיפות נורמלית סטנדרטית מעליה נראית קרובה מאוד, במיוחד בין −3 ל-3.
- מה שחשוב הוא נורמליות באזור האחוזונים שמעניינים אותנו (3 עד 97, בערך 2± סטיות תקן), לא בזנבות הרחוקים. בהמשך הקורס לא נניח נורמליות, אבל לצורך זיהוי חריגים היא נוחה.

שלב 7: צפוי מול נצפה

מספר התצפיות הצפוי מחוץ ל-±k סטיות תקן תחת נורמליות:

```
E[\#\{|Z|>k\}] = n \cdot 2\,\Phi(-k)
```

נצפה	צפוי (n ≈ 56,000)	מחוץ לטווח
כ-33,000	כ-34,700	±0.5 סטיות תקן
605	152	±3 סטיות תקן
162	כ-4	±4 סטיות תקן
80	כ-0	±5 סטיות תקן
21	0	±7 סטיות תקן

שני לקחים מהטבלה:

- **במדגם גדול צפויים חריגים אמיתיים.** הכלל "מעל 3 או 3.5 סטיות תקן מורידים" לא נכון כאן: ב-60,000 תצפיות נצפה בכ-26 תצפיות מעל 3.5 סטיות תקן גם בהתפלגות נורמלית תקינה.
- **כאן יש עודף ברור.** 605 מול 152 מעל 3, ו-80 מעל 5 כשאמורה להיות אפס.

שלב 8: ההחלטה כמה להוריד

אין תשובה אחת נכונה. האפשרויות שעלו:

- להוריד את ה-80 שמעל 5 סטיות תקן (פחות מ-0.5% מהנתונים, מפוזרים), או את ה-162 שמעל 4. המרצה בהדגמה הוריד מעל 7, ואמר שבדיעבד היה עדיף מעל 5.
- לבדוק רגישות: להריץ את הניתוח עם ובלי הסרת חריגים ולוודא שהתוצאות לא משתנות הרבה.
- לא להוריד (או להוריד מעט), ואז לבחור שיטה שאינה רגישה לחריגים, שבה לתצפית חריגה אין leverage גבוה על התוחלת וסטיית התקן.
- אם הנתונים לא נורמליים, מעלים את הסף, למשל מ-5 ל-7 סטיות תקן.

הערה: הנתונים משבוע 14 עד 40. בחלק מהמדדים ראינו שכדאי להוריד גם את השבועות הראשונים.

בדיקות חוזרות וסלקציה

החשש: הריונות עם הרבה בדיקות הם אלה שהיה בהם ערך קיצוני מוקדם, ולכן נשלחו למעקב. במקרה כזה התצפיות החריגות מיוצגות יותר מדי בקובץ. בהדגמה לא נמצא הבדל משמעותי.

שלב 1: ספירת בדיקות לכל הריון

לכל שורה מוסיפים משתנה: כמה בדיקות יש לאותו מזהה הריון. כשמסכמים את המשתנה בטבלה, צריך לזכור שהספירה היא של שורות:

- 19 שורות עם הערך 19 = הריון אחד שנבדק 19 פעמים.
- 26 שורות עם הערך 13 = שני הריונות שנבדקו 13 פעמים כל אחד.

שלב 2: הסרת כפילויות סמוכות

יש נשים שנבדקו כמה פעמים באותו יום או בימים סמוכים. סיבות אפשריות: אותו טכנאי הזין פעמיים, רופא בדק שוב אחרי הטכנאי, או שני טכנאים במסגרת הכשרה.

- הכלל שהוצע: בדיקות באותו הריון במרווח של עד כ-7 ימים = בדיקה אחת.
- מה לשמור: ממוצע הבדיקות, או הבדיקה האחרונה (בהנחה שהראשונה היא זו שהובילה לבדיקה השנייה). הבחירה בידיכם.
- בטבלת המרחקים בין בדיקות סמוכות רואים הרבה מקרים כאלה. מרחקים מעל 7 ימים מופיעים כשיש שני רצפים של בדיקות באותו הריון, ואפשר להתעלם מהם.

שלב 3: השוואה בין מעט בדיקות להרבה בדיקות

- מחלקים לשתי קבוצות: פחות מ-4 בדיקות (שגרה, כ-31,000 שורות) מול 4 בדיקות ומעלה (כ-24,000 שורות).

- משווים את התפלגות Z בשתי הקבוצות, במיוחד בשבועות המתקדמים.
- עדיף להשוות **פונקציות התפלגות מצטברות אמפיריות** זו ליד זו ולא צפיפויות: קל יותר לקרוא מהן הסתברויות.
- בהדגמה ההתפלגויות כמעט זהות. כלומר הבדיקות הנוספות נובעות כנראה מסיבות אחרות ולא מערכים חריגים. (בהדגמה המרצה שכח להוריד את החריגים לפני ההשוואה.)

מבחן קולמוגורוב-סמירנוב (KS)

מבחן לשאלה האם שתי דגימות באות מאותה התפלגות.

- פונקציית התפלגות אמפירית: לכל ערך x, שיעור התצפיות שקטנות ממנו. זה אומד לפונקציית ההתפלגות המצטברת.
- סטטיסטי המבחן הוא המרחק האנכי המקסימלי בין שתי הפונקציות:

```
D = \sup_x \left| \hat F_A(x) - \hat F_B(x) \right|
```

- תחת השערת האפס, ההתפלגות של D לא תלויה בהתפלגות האמיתית באוכלוסייה (הסטטיסטי אינווריאנטי). היא זהה למקרה שבו הגרלנו את שתי הקבוצות מהתפלגות אחידה U(0,1) באותם גדלים, ולכן קל לחשב p-value.
- בהדגמה יצא p-value ≈ 0.4, כלומר אין עדות להבדל.
- לא חובה להריץ KS. השוואה חזותית של הפונקציות המצטברות מספיקה.

אם מצאתם הבדל: דווחו עליו, אבל המשיכו את העבודה כאילו אין הבדל. בקורס הזה לא מטפלים בתיקון סלקציה.

חלוקה לקובץ אימון וקובץ בדיקה

החלוקה תהיה לפי שנים קלנדריות ולא אקראית: השנים המוקדמות לאימון, והשנים המאוחרות לבדיקה.

- **הסיבה:** העקומות שנבנה על הנתונים של היום ישמשו בשנים הבאות. חלוקה לפי זמן מחקה את המצב האמיתי: מתאימים על עבר ובודקים על עתיד.
- **מה זה תופס:** אם יש שינוי עם הזמן (שינוי במכשירים, בנוהלי מדידה וכו'), נגלה חוסר התאמה בין השנים. המרצה לא מצפה לשינוי באוכלוסיית העוברים עצמה.
- השיעור נעצר כאן, כשהמרצה התחיל להציג את פילוג הנתונים לפי שנה. נקודת החיתוך בין השנים לא נקבעה בתמלול.

מה צריך לעשות עכשיו

- [ ] להסיר ערכים בלתי אפשריים בעללים

- [ ] לבנות משתנה מתוקנן Z לפי שבוע (בכל שיטה סבירה)
- [ ] לספור חריגים מעל 3, 4, 5 ו-7 סטיות תקן, להשוות לצפוי תחת נורמליות, ולהחליט על סף עם נימוק
- [ ] לאחד בדיקות של אותו הריון במרווח של עד כשבוע לבדיקה אחת
- [ ] לבדוק סלקציה: להשוות את התפלגות Z בין הריונות עם פחות מ-4 בדיקות להריונות עם 4 ומעלה (פונקציות מצטברות, KS אופציונלי)
- [ ] לחלק לקובץ אימון וקובץ בדיקה לפי שנים

בשבוע הבא: שיטות לבניית עקומות מדויקות יותר ובחירת מודל.